

CONȚINUTUL CURSULUI #10:

- V. Minimizarea funcțiilor de două variabile.
- V.2. Forme pătratice, tipuri de extreme locale.
- V.3. Metoda gradientului conjugat.

Reamintim următoarele definiții:

Definiția (V.1.)

- a) Matricea  $A \in \mathcal{M}_n(\mathbb{R})$  se numește semipozitiv definită (seminegativ definită)  $\Leftrightarrow \langle Av, v \rangle \geq 0, \forall v \in \mathbb{R}^n$  ( $\langle Av, v \rangle \leq 0, \forall v \in \mathbb{R}^n$ ).
- b) Matricea  $A \in \mathcal{M}_n(\mathbb{R})$  s.n. pozitiv definită (negativ definită)  
 $\Leftrightarrow \langle Av, v \rangle > 0, \forall v \in \mathbb{R}^n$  și  $\langle Av, v \rangle < 0, \forall v \in \mathbb{R}^n$   
 $\Leftrightarrow \langle Av, v \rangle \geq 0, \forall v \in \mathbb{R}^n$  și  $\langle Av, v \rangle = 0 \Leftrightarrow v = \mathbf{0}_n$   
 $\Leftrightarrow \langle Av, v \rangle \leq 0, \forall v \in \mathbb{R}^n$  și  $\langle Av, v \rangle = 0 \Leftrightarrow v = \mathbf{0}_n$
- c) Dacă matricea  $A$  nu este nici de tipul a), nici de tipul b) zicem ca aceasta este nedefinită.

Teorema (V.2. Criteriul lui Sylvester):

Fie  $A \in \mathcal{M}_n(\mathbb{R})$  simetrică. Atunci  $A$  este pozitiv (negativ) definită

$$\Leftrightarrow \det A_k > 0, (\text{sign}(\det A_k) = (-1)^k), k = \overline{1, n}$$

unde  $A_k = (a_{ij})_{i,j=1,k}$ .

În continuare, vom da câteva exemple de forme pătratice și vom discuta tipul punctelor de extrem pe care acestea le admit. Fie forma patratca  $f(x, y) = \left\langle A \begin{pmatrix} x \\ y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle, A \in \mathcal{M}_2(\mathbb{R})$  simetrică. Funcția  $f$  se scrie desfășurat astfel:

$$\begin{aligned} f(x, y) &= \left\langle \begin{pmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle \\ &= \left\langle \begin{pmatrix} a_{11}x + a_{12}y \\ a_{12}x + a_{22}y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle \\ &= (a_{11}x + a_{12}y) \cdot x + (a_{12}x + a_{22}y) \cdot y \\ &= a_{11}x^2 + 2a_{12}x \cdot y + a_{22}y^2 \end{aligned}$$

Exemplu ( 1.)

a)  $f(x, y) = \left\langle A \begin{pmatrix} x \\ y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle, A = \begin{pmatrix} 4 & 1 \\ 1 & 2 \end{pmatrix}$ . Matricea  $A$  este simetrică, mai mult  $\Delta_1 = 4 > 0, \Delta_2 = \begin{vmatrix} 4 & 1 \\ 1 & 2 \end{vmatrix} = 7 > 0$ , deci  $A$  este pozitiv definită. Conform reprezentării grafice, funcția  $f$  admite punct de minim local.




Figure: Reprezentarea grafică a funcției  $z = 4x^2 + 2xy + 2y^2$

### Exemplu (1.)

b)  $f(x, y) = \left\langle A \begin{pmatrix} x \\ y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle, A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ . Matricea  $A$  este simetrică, mai mult  $\Delta_1 = 1 > 0, \Delta_2 = 1 > 0$ , deci  $A$  este pozitiv definită. Conform reprezentării grafice, funcția  $z = x^2 + y^2$  admite punct de minim local. Pozitiv definirea se mai poate demonstra și conform definiției:

$$f(x, y) = x^2 + y^2 \geq 0, \forall (x, y) \in \mathbb{R}^2$$

$$f(x, y) = 0 \Leftrightarrow x^2 + y^2 = 0 \Leftrightarrow x = y = 0$$




Figure: Reprezentarea grafică a funcției  $z = x^2 + y^2$

Curs #10

June 6, 2023

5 / 12

### Exemplu (2.)

b)  $f(x, y) = \left\langle A \begin{pmatrix} x \\ y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle, A = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}$ . Matricea  $A$  este simetrică, mai mult  $\Delta_1 = -1 < 0, \Delta_2 = 1 > 0$ , deci  $A$  este negativ definită. Conform reprezentării grafice, funcția  $z = -(x^2 + y^2)$  admite punct de maxim local. Negativ definirea se mai poate demonstra și conform definiției:

$$f(x, y) = -(x^2 + y^2) \leq 0, \forall (x, y) \in \mathbb{R}^2$$

$$f(x, y) = 0 \Leftrightarrow -(x^2 + y^2) = 0 \Leftrightarrow x = y = 0$$




Figure: Reprezentarea grafică a funcției  $z = -x^2 - y^2$

Curs #10

June 6, 2023

6 / 12

### Exemplu (3.)

$$f(x, y) = x^2 - 2xy + y^2.$$

$$A = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

$$f(x, y) = (x - y)^2 \geq 0, \forall (x, y) \in \mathbb{R}^2$$

$$f(x, y) = 0 \Leftrightarrow x - y \Leftrightarrow x = y \Rightarrow (x, x), \forall x \in \mathbb{R}$$

Am găsit mai multe puncte de forma  $(x, x)$  astfel încât  $f(x, x) = 0$ , deci  $f$  este semipozitiv definită. Funcția  $f$  admite o infinitate de puncte de minim.




Figure: Reprezentarea grafică a funcției  $z = x^2 - 2xy + y^2$

Curs #10

June 6, 2023

7 / 12

### Exemplu (4.)

$$f(x, y) = -(x^2 - 2xy + y^2) \Rightarrow$$

$$f(x, y) = -(x - y)^2 \leq 0, \forall (x, y) \in \mathbb{R}^2$$

$$f(x, y) = 0 \Leftrightarrow x = y \Rightarrow f \text{ este seminegativ definită}$$

Am găsit mai multe puncte de forma  $(x, x)$  astfel încât  $f(x, x) = 0$ , deci  $f$  este semipozitiv definită. În acest caz funcția  $f$  admite o infinitate de puncte de maxim.




Figure: Reprezentarea grafică a funcției  $z = x^2 - 2xy + y^2$

Curs #10


June 6, 2023

8 / 12

$$f(x, y) = 2x^2 + 8xy + 2y^2, A = \begin{pmatrix} 2 & 4 \\ 4 & 2 \end{pmatrix}$$

$$f(x, y) = (\sqrt{2}x)^2 + 2\sqrt{2}x \cdot 2\sqrt{2}y + (2\sqrt{2}y)^2 - (2\sqrt{2}y)^2 + 2y^2 \\ = (\sqrt{2}x + 2\sqrt{2}y)^2 - 6y^2$$

Dacă alegem  $(x, y) = (0, 1)$  se obține  $f(0, 1) = 8 - 6 = 2 > 0$ , însă dacă alegem  $(x, y) = (-1, 1) \Rightarrow f(-1, 1) = -4 < 0$ . În concluzie,  $f$  nu este nici pozitiv/semipozitiv definită, nici negativ/seminegativ definită. În acest caz o vom numi nedefinită. Funcția nu admite nici punct de minim, nici punct de maxim, ci punct șa.



Curs #10

June 6, 2023

9 / 12

## V. Minimizarea funcțiilor de două variabile.

## V.3. Metoda gradientului conjugat.

Metoda gradientului conjugat presupune aflarea punctului de minim în doi pași.

Fie  $(x_0, y_0) \in D$ , unde  $D$  reprezintă domeniului de definiție al funcției  $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$ . Alegem la primul pas, analog metodei pasului descendent,  $v^{(0)} = \nabla f|_{(x_0, y_0)}$ . Vom construi, de data aceasta,  $v^{(1)}$  astfel încât  $\langle v^{(1)}, Av^{(0)} \rangle = 0$ . Se spune că vectorul  $v^{(1)}$  este  $A$ -ortogonal pe  $v^{(0)}$ .

La fiecare pas  $k$ ,  $k = \overline{1, 2}$ , vom nota  $r^{(k)} = b - Ax^{(k)}$ , semnificând restul la fiecare iterație. Amintim că dorim să minimizăm funcția

$$f(x, y) = \frac{1}{2} \left\langle A \begin{pmatrix} x \\ y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle - \left\langle \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle,$$

unde  $A$  este o matrice simetrică și pozitiv definită. Aceste cerințe asupra matricei  $A$  asigură existența unui punct de minim local și astfel să putem aplica metode de calcul al punctului de minim local.

Curs #10

June 6, 2023

10 / 12

Considerăm  $v^{(1)}$  de forma  $v^{(1)} = -r^{(1)} + \beta_0 v^{(0)}$ , unde coeficientul  $\beta_0$  se va calcula astfel încât  $\langle v^{(1)}, Av^{(0)} \rangle = 0$ , condiție echivalentă cu  $\langle -r^{(1)} + \beta_0 v^{(0)}, Av^{(0)} \rangle = 0$ , de unde rezultă

$$\beta_0 = \frac{\langle r^{(1)}, Av^{(0)} \rangle}{\langle v^{(0)}, Av^{(0)} \rangle}$$

Cu excepția modalității de calcul a noii direcții, algoritmul gradientului conjugat rămâne similar cu algoritmul pasului descendent.

## ALGORITM (Metoda gradientului conjugat)

**Date de intrare:**  $A \in M_2(\mathbb{R})$  - simetrică și pozitiv definită,  $b \in \mathbb{R}^2$

**Date de ieșire:**  $x^{(2)}$

- 1:
  - $x^{(0)} = (x_0, y_0) \in D \subset \mathbb{R}^2$  - ales arbitrar
  - $r^{(0)} = b - Ax^{(0)} = -\nabla f|_{(x_0, y_0)}$  - se calculează restul
  - $v^{(0)} = -r^{(0)}$  - se alege  $v^{(0)}$  după direcția gradientului
  - $\alpha_0 = \frac{\langle v^{(0)}, r^{(0)} \rangle}{\langle v^{(0)}, Av^{(0)} \rangle}$
- 2:
  - $x^{(1)} = x^{(0)} - \alpha_0 v^{(0)}$
  - $r^{(1)} = b - Ax^{(1)}$
  - $\beta_0 = \frac{\langle r^{(1)}, Av^{(0)} \rangle}{\langle v^{(0)}, Av^{(0)} \rangle}$
  - $v^{(1)} = -r^{(1)} + \beta_0 v^{(0)}$
  - $\alpha_1 = \frac{\langle v^{(1)}, r^{(1)} \rangle}{\langle v^{(1)}, Av^{(1)} \rangle}$
- 3:
  - $x^{(2)} = x^{(1)} - \alpha_1 v^{(1)}$
  - STOP

**Obs.:** Se poate demonstra ușor că  $x^{(2)}$  reprezintă soluția sistemului  $Ax = b$  care este chiar punctul de minim al funcției  $f$ .